

# Insider Threat - Analisando Comportamento de Usuários para Detecção de Ameaças Internas

Abraão Vitor L. Dantas<sup>1</sup>, Henrique David de Medeiros<sup>1</sup>

<sup>1</sup> Instituto Metr pole Digital

Universidade Federal do Rio Grande do Norte (UFRN) – Natal, RN – Brasil

abraaovld@gmail.com, henriquemed101@gmail.com

## 1. Introdu  o

Atualmente com a revolu  o das tecnologias de informa  o, a preocupa  o com seguran a da informa  o por parte das empresas tem aumentado consideravelmente. Em uma pesquisa realizada no ano de 2016 pela empresa PWC-Brasil, no Brasil houve um aumento de 274% nos incidentes de seguran a da informa  o. E nessa estat stica n o se contabiliza os casos em que as empresas n o relatam ataques, que se imagina serem muitos.

Apesar da exist ncia de ataques externos, um dos que mais preocupa atualmente s o os ataques internos (denominado "insider attacker" ou "insider threat") [Legg et al. 2015], [Cole 2015]. Tais amea as internas s o caracterizadas por usu rios que fazem parte de empresas e que por terem certas permiss es de acesso as exploram para comprometer a seguran a da organiza  o e de seus sistemas [Silowash et al. 2012], [Cappelli et al. 2012].

O nosso trabalho visa ent o ser capaz de detectar ataques internos atrav s da an lise de logs de atividade dos usu rios em busca de anomalias [Legg et al. 2015]. Com esta an lise cria-se uma  rvore capaz de agrupar todas as atividades dos usu rios e assim construir um perfil deste, permitindo fazer compara  es e identificar comportamentos an malos.

## 2. Abordagem de solu  o

O projeto foi desenvolvido para realizar a leitura de arquivos de log de usu rios, dentre eles uma pasta **LDAP** com arquivos, com extens o csv, de informa  es dos usu rios em per odos diferentes, **device.csv** com as informa  es dos dispositivos que foram conectados, **http.csv** com urls acessadas pelos usu rios e **logon.csv**, com os dispositivos em que foram realizados logon e logoff.

O sistema foi desenvolvido em linguagem de programa  o Java, utilizando as IDEs (Integrated Development Environment) Netbeans e Eclipse para a escrita do c digo fonte. Foram utilizadas bibliotecas externas como o JFreeChart, para a gera  o do gr fico visualmente; e da Commons Math para realizar o c lculo do *IQR(interquartile range)*.

O projeto completo   feito com base nos diagramas de classe presentes nas figuras 1 e 2. Existe uma classe chamada **Node** cuja as demais classes que comp em a estrutura de dados herdam, contendo apenas dois atributos,   uma classe bem simples cujo o construtor obriga que todos os filhos tenham um id, este    nico entre objetos das classes User e Device.

Para a execu  o do projeto temos a classe **Tree insiders** que ser  a classe respons vel por manter a estrutura da  rvore na mem ria, sendo respons vel pela constru  o

e leitura da árvore. Já a classe **FileReader** é a responsável por fazer a leitura dos arquivos de log e através de um objeto da **Tree insiders** chamar os métodos de criação. Finalmente a tarefa de construir os histogramas de cada usuário e fazer a análise destes fica a cargo da classe **Analyzer** e seus métodos.

Durante o desenvolvimento foram adotados padrões de projetos no que diz às estruturas de dados lineares que servem de auxílio, bem como na distribuição de pacotes de código fonte e sua organização.

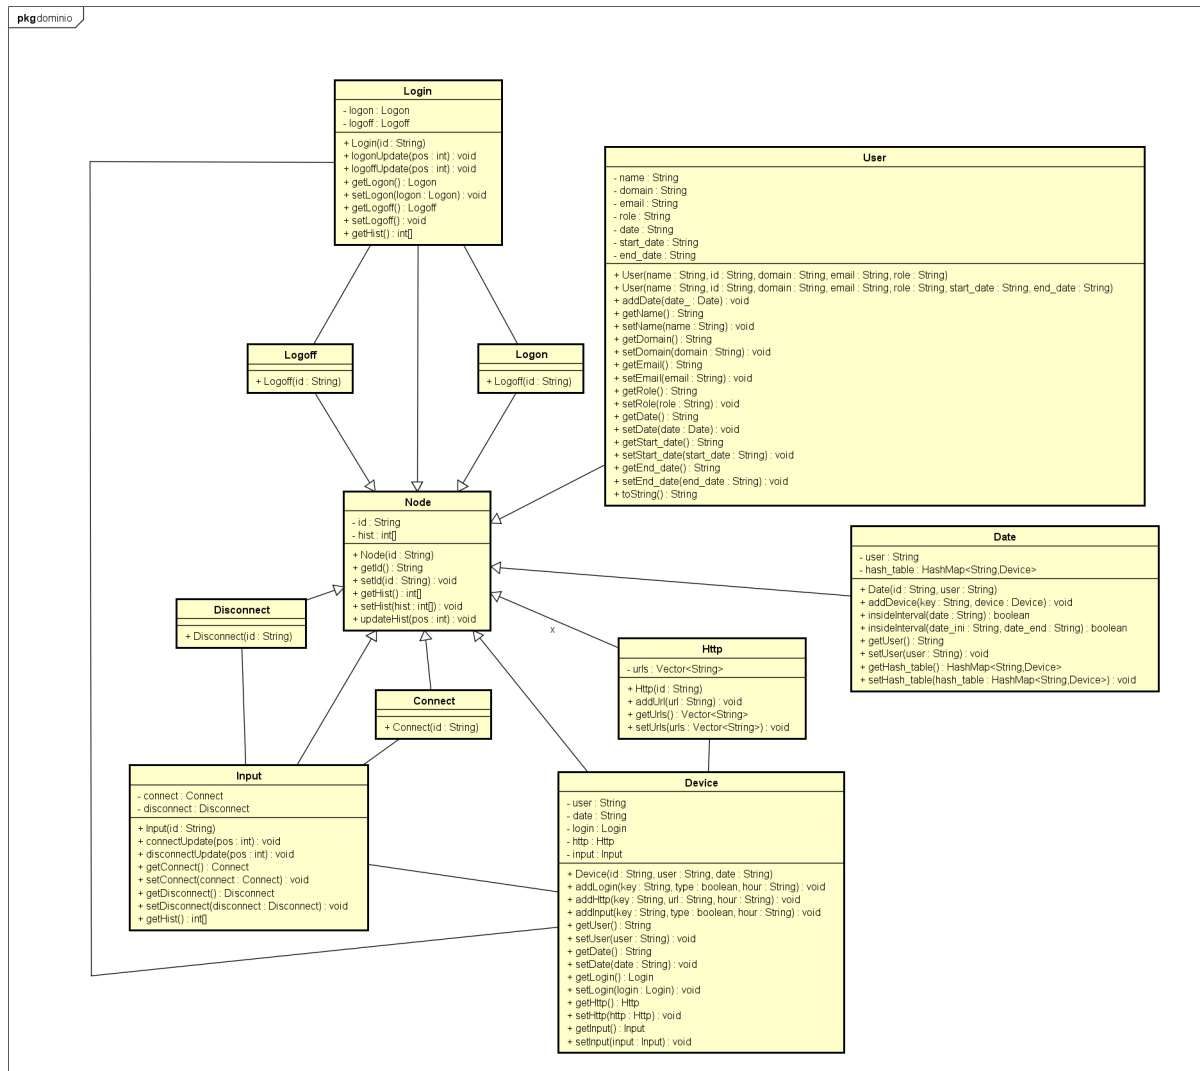


Figura 1. Diagrama de Classes 1

### 3. Estrutura de dados e Algoritmos Utilizados

Para a criação e análise dos perfis de usuário a estratégia abordada foi a de criar uma árvore genérica combinada a outra estrutura linear, no caso uma tabela de dispersão cujo o motivo da escolha será exposto mais a frente. O formato base da estrutura pode ser visualizado na figura 3.

Como é possível observar na figura 3 a tabela de dispersão aparece no 1º e 3º nível da árvore, isso se dar pelo fato que no primeiro nível podem existir  $n$  usuários, assim como

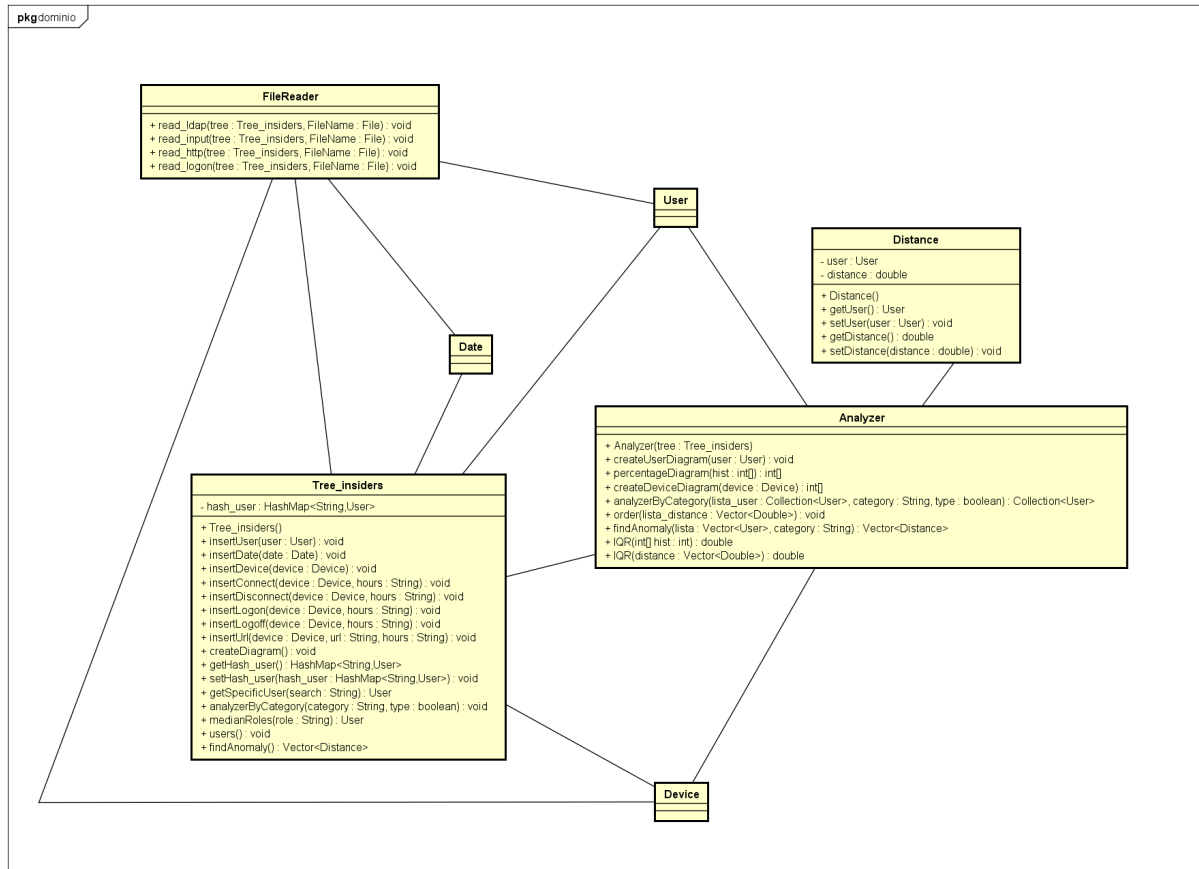


Figura 2. Diagrama de Classes 2


cada usuário pode ter usado  $n$  dispositivos. Como os outros nós são estáticos não se faria necessário usar uma estrutura auxiliar.

O motivo de escolha da tabela de dispersão para o projeto foi devido a complexidade de inserção e busca de  $\mathcal{O}(1)$  que a estrutura possui, levando em consideração que cada usuário, bem como dispositivo, possui um  $id$  único, o número de colisões da tabela seria bem reduzido tornando o seu uso viável. Deste modo o uso desta em combinação com uma árvore genérica permitiu inserções e leituras de maneira muito eficiente dos dados presentes nos arquivos de log.

### 3.1. Detectando Anomalias

Uma vez criada a árvore contendo os perfis dos usuários é necessário que se passa uma análise em busca de possíveis anomalias no comportamento destes. Considerando que cada usuário mantém um histograma de 24 posições onde cada uma representa uma hora do dia e contém o número de ações naquela hora, podemos então organizar o usuário por sua função dentro da empresa e traçar uma média para que seja calculada a distância entre o perfil de um usuário para o perfil médio, através da equação de distância Euclidiana.

$$D(h_A, h_M) = \sqrt{\sum_{n=0}^{23} (h_A[n] - h_M[n])^2} \quad (1)$$



**Figura 3. Estrutura de Dados**

Onde  $h_A$  é o histograma de um usuário e  $h_M$  é o histograma médio de um papel. Uma vez que se possui todas as distâncias de todos os usuários que desempenham o mesmo papel, utilizamos então um algoritmo de *IQR* (Variância Interquartil) com estas distâncias para encontrar o valor de variância, chegando a uma segunda equação para determinar que trata-se de uma anomalia:

$$D(h_A, h_M) \geq 1.5 * IQR \quad (2)$$

Ou seja, para que o perfil de um usuário seja tratado como uma anomalia é necessário que a distância entre seu perfil para o da média seja  $1.5x$  maior que o valor de *IQR*.

#### 4. Conclusão

Com a escolha de uma árvore genérica utilizando tabelas de dispersão para auxiliar, o desempenho na criação e leitura dos perfis mostrou-se bastante satisfatório. Além disso cuidados na hora da abertura do arquivo foram cruciais para o funcionamento correto da aplicação sem que houvesse falta de memória. Com um tema bem atual, como é o caso de segurança, foi possível exercitar todos os conceitos aprendidos na disciplina de Linguagem de Programação 2 e ir até um pouco mais além, já que foram utilizadas bibliotecas externas para enriquecer o software, além disso foi possível aplicar conhecimentos oriundos de outras disciplinas como Estruturas de Dados Básicas 1 e Estruturas de Dados Básicas 2.

#### Referências

Cappelli, D. M., Moore, A. P., and Trzeciak, R. F. (2012). *The CERT guide to insider threats: how to prevent, detect, and respond to information technology crimes (Theft, Sabotage, Fraud)*. Addison-Wesley.

- Cole, E. (2015). Insider threats and the need for fast and directed response. *SANS Institute InfoSec Reading Room, Tech. Rep.*
- Legg, P. A., Buckley, O., Goldsmith, M., and Creese, S. (2015). Caught in the act of an insider attack: detection and assessment of insider threat. In *Technologies for Homeland Security (HST), 2015 IEEE International Symposium on*, pages 1–6. IEEE.
- Silowash, G., Cappelli, D., Moore, A., Trzeciak, R., Shimeall, T. J., and Flynn, L. (2012). Common sense guide to mitigating insider threats 4th edition. Technical report, CARNEGIE-MELLON UNIV PITTSBURGH PA SOFTWARE ENGINEERING INST.